

Taller de SQL

De una factura a hallazgos relevantes para nuestro cliente

Dr. Martín Lozano · martin.lozano@udem.edu

<https://mlozanoqf.github.io/>

Actualizado el 09/10/2026 a las 12:15:53

1. Nuestro cliente y nuestro papel

Nuestro cliente es una empresa minorista que considera comprar más mercancía, vender en otros países y probar promociones. Nosotros somos sus consultores. Le ayudaremos a entender sus ventas y a decidir con evidencia. **¿Qué podemos recomendarle con estos datos y qué necesitamos saber antes de actuar?**

El cliente y la situación son hipotéticos. Los datos son reales de *UCI Online Retail*, un comercio británico por internet que vendía regalos y atendía a muchos mayoristas. Cuando hablemos de los clientes de la tienda, nos referiremos a sus compradores.

Partiremos de una factura comprensible y reuniremos los datos por país, artículo, hora y día para encontrar patrones. Entregaremos a nuestro cliente un diagnóstico con **hallazgos relevantes, recomendaciones y lo que falta comprobar antes de actuar**.

Qué es SQL y de dónde viene

SQL es un lenguaje declarativo para consultar y organizar datos en tablas. Indicamos qué resultado buscamos, por ejemplo ventas por país. El programa que ejecuta SQL decide cómo obtenerlo. Donald Chamberlin y Raymond Boyce lo desarrollaron en IBM en los años setenta, inicialmente como SEQUEL. Historia de IBM.

¿Es gratis? ¿Dónde trabajaremos?

SQL es el lenguaje. **SQLite es el motor que ejecutará nuestras consultas.** Los motores y servicios tienen distintas licencias y costos. No todo producto que usa SQL es gratuito ni software libre. SQLite es de dominio público y no requiere pagar una licencia para usarlo.

Trabajaremos en <https://sqlime.org/>, una web que ejecuta SQLite en el navegador. Abrir nuestro archivo y ejecutar estas consultas no requiere pago ni una cuenta nueva. No necesitamos RStudio. Las opciones de compartir con GitHub o usar IA quedan fuera del taller. Después podríamos usar R o Python para analizar o graficar los datos organizados con SQL.

Qué vamos a averiguar
SQL, factura real, plataforma y alcance
Qué cifra de ventas presentar
Cuánto depende nuestro cliente de cada país
Qué revisar antes de comprar más mercancía
Cómo evolucionan las ventas y qué comprobar antes de ampliar capacidad
Cuándo probar una promoción
Cómo escribir hallazgos y recomendaciones

Puedes seguir el tutorial por tu cuenta o en clase. Lee cada pregunta, ejecuta la consulta y compara el resultado con su explicación antes de decidir qué recomendarías a nuestro cliente. Las consultas del recorrido principal se identifican por su código para encontrarlas en los archivos SQL. Las extensiones desarrollan temas independientes que podemos usar para ampliar la sesión si hay tiempo.

2. Una factura real para empezar el análisis

¿Qué información contiene una factura?

Este es el contenido completo del documento **536365** en los datos de UCI. Es una tabla de sus registros, no una reproducción de un comprobante fiscal. Cada renglón de la factura registra un artículo o cargo, su cantidad y su precio. Los datos comunes a sus siete renglones aparecen primero.

Para facilitar el trabajo, esta base traduce `descripcion` y `pais` al español, con una correspondencia para cada texto original. No rellena los valores NULL. Las marcas [variante Dnnnn] distinguen textos que quedarían iguales al traducirlos; no indican artículos nuevos. Los originales y el diccionario están en los recursos.

Campo original → campo en SQLite	Valor guardado en la base
InvoiceNo → factura	536365
InvoiceDate → fecha	2010-12-01 08:26:00
Country → país	Reino Unido

Código	Descripción	Unidades	GBP/unidad	GBP renglón
85123A	Portavelas de té colgante de corazón blanco	6	2.55	15.30
71053	Farol metálico blanco	6	3.39	20.34
84406B	Gancho para ropa color crema con corazones de Cupido	8	2.75	22.00
84029G	Bolsa de agua caliente con tejido de bandera británica	6	3.39	20.34
84029E	Bolsa de agua caliente roja con cubierta de aspecto lanoso y corazón blanco	6	3.39	20.34
22752	Juego de 7 cajas encajables de muñeca babushka	2	7.65	15.30
21730	Portavelas de té de estrella de vidrio esmerilado	6	4.25	25.50

Total del documento — 7 renglones, 40 unidades y 139.12 GBP.

En 2010-12-01 08:26:00, la fecha es el 1 de diciembre de 2010 y la hora es 08:26, con segundos 00. El campo original se llama `InvoiceDate`. Al preparar SQLite se guardó como texto en el formato **año-mes-día hora:minuto:segundo**. Este es el formato que veremos y consultaremos, sin añadir una zona horaria.

El primer renglón contiene seis portavelas blancos con forma de corazón a 2.55 GBP cada uno. **6 × 2.55 = 15.30 GBP** es el valor de ese renglón. Los otros seis se calculan igual. Siete renglones no son siete facturas ni siete clientes. Tampoco son siete unidades. La factura completa tiene 40 unidades registradas. Una unidad corresponde a la presentación del artículo. Una unidad de un juego de siete cajas es un juego, no siete unidades. **GBP significa libras esterlinas.**

`importe_gbp` es el nombre técnico de cantidad por precio. Ese valor no mide utilidades, costo ni cobro comprobado. Más adelante reuniremos muchas facturas para descubrir qué países, artículos y horarios concentran las ventas.

3. Abrir la base y consultar sus campos

¿Qué representa cada columna y cómo consultamos esta factura?

1. Entra en la página del taller y descarga `ventas.sqlite`. Guárdalo en tu equipo. No necesitas descomprimirlo.
2. Abre <https://sqlime.org/> en el navegador.
3. Pulsa **open file** y elige `ventas.sqlite` en la carpeta donde lo guardaste.
4. Copia Q1 de la página siguiente, también incluida en `consultas.sql`, pégala en el editor y pulsa **Run** o **Ctrl+Enter** (**Cmd+Enter** en macOS). Verás los siete renglones de la factura.

Campo en SQLite	Qué significa
<code>fila_origen</code>	Fila del Excel original, para volver al dato.
<code>factura</code>	Código del documento. El prefijo C identifica una cancelación según UCI.
<code>producto</code>	Código del artículo o cargo. También hay gastos de envío y anotaciones manuales.
<code>descripcion</code>	Nombre del artículo o cargo. Puede faltar o variar.
<code>cantidad</code>	Número de unidades del renglón. Algunas cantidades son negativas.
<code>precio_gbp</code>	Precio por unidad en GBP, no costo unitario.
<code>fecha</code>	Fecha y hora del registro, procedentes de <code>InvoiceDate</code> .
<code>pais</code>	País de residencia del comprador según UCI.

Cómo leer los colores del código

En los bloques SQL de este PDF, el **rojo** destaca instrucciones como `SELECT`, `FROM` y `WHERE`, y algunos operadores. El **azul**, funciones como `SUM`, `COUNT` y `AVG`. El **negro**, nombres de tablas y columnas. El **verde**, textos entre comillas simples. El **magenta**, números. Y el **gris**, comentarios.

Es una ayuda visual, no una regla de SQL ni una señal de error. La clasificación no es perfecta. Por ejemplo, `ROUND` aparece negro aunque es una función. **En Sqlime los colores pueden ser distintos.** Lo que se ejecuta es el texto.

Leer y ejecutar la primera consulta

SELECT elige columnas o cálculos. FROM indica la tabla. WHERE selecciona filas y ORDER BY ordena la salida. AS da nombre a un resultado y ROUND(..., 2) muestra dos decimales.

En esta consulta, SELECT elige los datos del documento y calcula el valor de cada renglón multiplicando cantidad por precio. ROUND(..., 2) redondea ese valor a dos decimales y AS le da el nombre valor_linea_gbp. FROM lee lineas, WHERE conserva la factura 536365 y ORDER BY recupera el orden del archivo original. No aplicamos LIMIT porque queremos verla completa.

Q1.

```
/* Recuperamos los siete renglones del mismo documento. */
-- Elegimos datos que identifican documento, país y artículo.
SELECT factura, fecha, pais, producto, descripcion,
       cantidad, precio_gbp, -- Unidades y precio por unidad.
       -- Multiplicamos y redondeamos el valor de cada renglón.
       ROUND(cantidad * precio_gbp, 2) AS valor_linea_gbp
FROM lineas -- Leemos todos los registros originales preparados.
WHERE factura = '536365' -- Conservamos esta factura completa.
ORDER BY fila_origen; -- Recuperamos el orden del archivo fuente.
```

Comentarios que ayudan a leer SQL

En R usamos #. En SQLite usamos -- para comentar hasta el final de la línea, o /* ... */ para un comentario de una o varias líneas. El texto comentado no se ejecuta. Q1 muestra un comentario de bloque y las otras consultas usan comentarios dentro de la consulta para explicar filtros, agrupaciones y cálculos.

El **punto y coma ; termina una consulta**, no inicia un comentario. En las cifras de este PDF, ; separa millones, , miles y . decimales, como en **1;234,567.89**. Es solo presentación. Al escribir una cantidad en SQL, usa **1234567.89**, sin separadores de millones o miles. Los códigos como 536365, las fechas y los datos originales conservan su formato.

Los bloques SQL son independientes. Con esta base abierta no requieren consultas previas. Las vistas están guardadas y cada WITH pertenece a su bloque. No usamos LIMIT 5 porque ocultaría dos renglones. Guarda las consultas en mis-consultas.sql. Si tarda la carga, lee los resultados incluidos y vuelve a intentarlo después.

lineas guarda los renglones de factura. movimientos es una vista que añade importe_gbp y cancelacion, que vale 1 para el prefijo C. ventas es otra vista cuyo filtro explicaremos al calcular el total. La base omite CustomerID. No permite contar clientes distintos ni saber cuáles vuelven a comprar. Una cantidad negativa no demuestra una devolución física y la marca C no explica por qué se canceló.

4. De una factura al archivo completo

Pregunta de negocio

¿De qué fechas tenemos datos? ¿Qué diferencia hay entre contar renglones de factura, contar facturas y sumar unidades vendidas?

SQL y resultado

COUNT(*) cuenta filas. MIN y MAX encuentran los extremos de fecha. COUNT(DISTINCT factura) cuenta códigos de documento diferentes.

FROM lineas toma todos los registros de la tabla. SELECT COUNT(*) los cuenta y AS lineas nombra la cifra resultante. Como no hay WHERE, ningún renglón queda fuera. Este conteo no suma cantidades ni distingue documentos.

Q2.

```
-- COUNT(*) cuenta renglones, no facturas, clientes ni unidades.  
SELECT COUNT(*) AS lineas -- AS da un nombre al resultado.  
FROM lineas; -- Contamos la tabla completa, sin filtro.
```

lineas
541,909

FROM lineas incluye todo el archivo. En SELECT, MIN(fecha) obtiene la fecha más temprana y MAX(fecha) la más tardía. COUNT(DISTINCT factura) cuenta cada código de documento una sola vez, aunque aparezca en muchos renglones. AS asigna un nombre a cada resultado.

Q3.

```
-- MIN y MAX buscan los extremos de las fechas registradas.  
SELECT MIN(fecha) AS primera_fecha,  
       MAX(fecha) AS ultima_fecha,  
       -- DISTINCT cuenta cada código de documento una sola vez.  
       COUNT(DISTINCT factura) AS facturas  
FROM lineas; -- Incluye documentos positivos y cancelaciones.
```

primera_fecha	ultima_fecha	facturas
2010-12-01 08:26:00	2011-12-09 12:50:00	25,900

Qué significa y qué haríamos

Tenemos **541,909 renglones**, del **1 de diciembre de 2010 al 9 de diciembre de 2011**, sin muestreo. Los códigos de factura incluyen documentos de cancelación. No deben presentarse como número de clientes ni de compras positivas. La base conserva vacíos, signos, repeticiones y valores extremos.

En la siguiente sección sumaremos las unidades que cumplen nuestro criterio de venta. Indicaremos estas fechas en el informe para nuestro cliente. Al comparar meses, señalaremos **diciembre de 2011, que termina el día 9**. No podemos compararlo directamente con meses completos. El archivo no contiene las ventas del resto de ese mes.

La fuente UCI Online Retail proporciona el Excel original. Para reproducir este tutorial usamos la base ventas.sqlite enlazada al abrir Sqlime. Las soluciones a problemas de apertura y consulta están al final, en archivos y reproducción.

5. Decisión 1 · Qué cifra de ventas presentar

Pregunta de negocio

Nuestro cliente quiere saber cuánto vendió durante el periodo. ¿Qué cifra le presentaríamos y cómo la explicaríamos?

SQL y resultado

Para responder, sumaremos los renglones **sin marca de cancelación, con cantidad mayor que cero y precio mayor que cero**. Llamaremos a este cálculo *ventas seleccionadas*. Primero veremos el total sin cancelaciones y después cuánto cambia al incluirlas. Los demás renglones permanecen en la base. WHERE filtra antes de sumar; AND combina condiciones que deben cumplirse a la vez y SUM acumula valores. Redondeamos el total al final.

FROM movimientos aporta los renglones con su valor calculado. WHERE conserva los que no tienen marca C y tienen cantidad y precio positivos. AND exige cumplir las tres condiciones. Sobre esa selección, COUNT(*) cuenta renglones y SUM suma unidades y valores de venta. ROUND redondea el total monetario, y AS nombra cada columna.

Q4.

```
SELECT COUNT(*) AS lineas_venta, -- Contamos renglones seleccionados.
       SUM(cantidad) AS unidades, -- Sumamos sus unidades.
       -- Sumamos valores de venta; redondeamos el total al final.
       ROUND(SUM(importe_gbp), 2) AS importe_gbp
FROM movimientos -- La vista calcula cantidad por precio.
WHERE cancelacion = 0 -- Excluimos documentos con prefijo C.
  AND cantidad > 0 -- Exigimos unidades positivas.
  AND precio_gbp > 0; -- Exigimos también precio positivo.
```

lineas_venta	unidades	importe_gbp
530,104	5;588,376	10;666,684.54

La vista ventas aplica exactamente ese filtro. Q5, en consultas.sql, comprueba que da la misma cifra. Puedes ejecutarla para comprobar que ambas formas dan el mismo resultado. La columna importe_gbp significa valor de venta calculado en GBP.

Qué significa y qué haríamos

Las ventas seleccionadas suman 10;666,684.54 GBP, en 530,104 renglones y 5;588,376 unidades. Es el total antes de incluir cancelaciones. Quedan fuera de este cálculo **11,805 renglones**, que conservamos para poder revisarlos.

Ya tenemos una cifra para hablar del tamaño de las ventas durante el periodo. Para que nuestro cliente pueda comprobarla, entregaremos la consulta junto con el total. En la siguiente página veremos cuánto cambia con las cancelaciones.

El valor de las ventas no mide las utilidades. No tenemos datos de costos para calcular cuánto ganó la empresa, ni registros de cobros para saber cuánto dinero recibió. Para usar este cálculo en la contabilidad habría que comprobarlo contra los documentos contables. SQLite almacena estos precios como números aproximados. Redondeamos el total a dos decimales para este análisis.

6. La misma decisión, incluyendo cancelaciones

Pregunta de negocio

¿Cuánto cambia esa cifra al incluir las cancelaciones registradas en el periodo?

SQL y resultado

Sumaremos los renglones cuya factura **empieza por C, con cantidad menor que cero y precio mayor que cero**. Es nuestro criterio para incluir cancelaciones. Su valor es negativo, por lo que lo sumamos a las ventas, sin restarlo una segunda vez. Llamaremos al resultado **valor neto registrado según el criterio del taller**. En la consulta Q6 aparece con el nombre técnico balance.

FROM movimientos permite revisar también las cancelaciones. WHERE y AND seleccionan únicamente los renglones con marca C, cantidad negativa y precio positivo. COUNT(*) cuenta esos renglones y SUM(importe_gbp) suma su valor con signo negativo. ROUND redondea el total y AS lo identifica como cancelaciones_gbp.

Q7.

```
SELECT COUNT(*) AS lineas, -- Contamos renglones cancelados del filtro.
        -- El total conserva su signo negativo para calcular el neto.
        ROUND(SUM(importe_gbp), 2) AS cancelaciones_gbp
FROM movimientos -- Incluye documentos con y sin prefijo C.
WHERE cancelacion = 1 -- Elegimos documentos con prefijo C.
      AND cantidad < 0 -- Exigimos cantidad negativa.
      AND precio_gbp > 0; -- Exigimos precio positivo, sin invertir signos.
```

lineas	cancelaciones_gbp
9,288	−896,812.49

Medida	Valor
Ventas antes de cancelaciones	10;666,684.54 GBP
Cancelaciones incluidas	−896,812.49 GBP
Valor neto según nuestro criterio	9;769,872.05 GBP
Reducción respecto de las ventas iniciales	8.41 %

Qué significa y qué haríamos

El total baja **8.41 %** al incluir estas cancelaciones. Se calcula dividiendo el valor absoluto de las cancelaciones por las ventas iniciales y multiplicando por 100. **Presentaríamos ambas cifras**, con sus nombres, para que nadie confunda ventas antes y después de cancelaciones. La extensión «Transferir y comprobar las consultas» explica cómo verificar esta suma con SQL. El cálculo no incluye todos los renglones del archivo, solo los que cumplen los dos criterios explicados. Tampoco hemos relacionado cada cancelación con su factura original. Algunas pueden corresponder a ventas de otras fechas. Por eso el 8.41 % **no es una tasa de devolución de los pedidos vendidos durante el periodo**. Una cantidad negativa o una marca C no explican qué ocurrió.

Si nuestro cliente quiere reducir las cancelaciones, le propondríamos revisar los documentos y sus motivos. Después podría decidir si necesita cambiar un proceso de venta, envío o registro. Estos datos solos no identifican la causa.

7. Decisión 2 · Dependencia comercial por país

Pregunta de negocio

¿Qué proporción de las ventas proviene de cada país? ¿Cómo explicaríamos a nuestro cliente su dependencia del mercado británico?

SQL y resultado

Usamos `ventas`, con el mismo criterio de la primera suma. `GROUP BY pais` reúne renglones por país; `ORDER BY ... DESC` ordena de mayor a menor. `LIMIT 5` muestra cinco grupos, pero la suma de cada uno usa todos los renglones que cumplen el filtro.

`FROM ventas` parte del filtro de ventas positivas ya guardado. `GROUP BY pais` reúne los renglones de cada país. `SELECT` muestra el país, `COUNT(*)` cuenta sus renglones y `SUM` calcula su valor total. `ROUND` deja dos decimales y `AS` nombra las medidas. `ORDER BY ... DESC` ordena de mayor a menor valor, con desempate por país. `LIMIT 5` conserva cinco países después de calcular todos los grupos.

Q8.

```
SELECT pais, COUNT(*) AS lineas, -- País y número de renglones.
        -- Calculamos el valor de venta total de cada país.
        ROUND(SUM(importe_gbp), 2) AS importe_gbp
FROM ventas -- Solo cantidades y precios positivos, sin C.
GROUP BY pais -- Formamos un grupo por país antes de sumar.
ORDER BY importe_gbp DESC, pais -- Mayor valor; empate por país.
LIMIT 5; -- Mostramos los cinco primeros grupos, no cinco ventas.
```

pais	lineas	importe_gbp
Reino Unido	485,123	9;025,222.08
Países Bajos	2,359	285,446.34
Irlanda	7,890	283,453.96
Alemania	9,040	228,867.14
Francia	8,407	209,715.11

Reino Unido aporta **9;025,222.08 GBP**, el **84.61 % de las ventas seleccionadas**. Dividimos por el total de Q4 (10;666,684.54 GBP), no por la suma de los cinco países mostrados.

Qué significa y qué haríamos

Casi 85 de cada 100 GBP de ventas proceden del Reino Unido. Esta dependencia no se aprecia en una factura aislada. Aparece al sumar las ventas de cada país. Una caída en ese mercado afectaría a gran parte del negocio. Proponemos calcular cuánto bajarían las ventas totales bajo distintos escenarios de caída británica, para decidir qué gastos o compras convendría ajustar en cada caso.

Fuera del Reino Unido destacan Países Bajos e Irlanda. Sus ventas son muy próximas. La diferencia es de **1,992.38 GBP**. Conviene estudiar ambos antes de elegir dónde intentar crecer. Q9 muestra esa comparación sin Reino Unido.

Podríamos probar una campaña pequeña en uno de esos países si los costos de envío, el margen y la capacidad para atender pedidos lo permiten. La comparación actual sirve para elegir qué investigar primero. No demuestra dónde sería rentable expandirse ni qué parte del mercado tiene la empresa.

8. Decisión 3 · Qué artículos investigar primero

Pregunta de negocio

¿Qué artículos conviene revisar primero para planear las compras? ¿Elegiríamos los mismos si nos fijamos en las unidades vendidas o en el valor de las ventas?

SQL y resultado

Agrupamos por código y mantenemos el filtro de ventas. Q10 ordena por unidades y Q11 por valor de venta. COUNT(*) contaría renglones, no unidades ni clientes. El PDF añade al código la descripción no vacía más frecuente. En caso de empate, la primera alfabéticamente. Es una etiqueta observada, no un nombre oficial. Se añade después del cálculo, sin unir filas. SQL conserva el código. Por ejemplo, el código 22197 tiene más de una descripción; Q12 revisa otra ambigüedad.

Q10 · Resultado para comparar unidades y valor.

Artículo o cargo (código)	unidades
Manualidad de papel, pajarito (23843)	80,995
Frasco mediano de almacenamiento con tapa de cerámica (23166)	78,033
Recipiente para palomitas (22197)	56,921
Planeadores de la Segunda Guerra Mundial con diseños surtidos (84077)	55,047
Bolsa extragrande roja con lunares retro (85099B)	48,474

FROM ventas conserva las ventas positivas. GROUP BY producto reúne los renglones de un mismo código, aunque sus descripciones varíen. En SELECT, SUM(cantidad) calcula las unidades y SUM(importe_gbp) el valor de venta. ROUND redondea este último y AS nombra ambos resultados. ORDER BY ... DESC prioriza el mayor valor y desempata por código. LIMIT 5 muestra los cinco primeros.

Q11.

```
SELECT producto, SUM(cantidad) AS unidades, -- Unidades por código.
      -- Sumamos el valor de sus renglones y redondeamos al final.
      ROUND(SUM(importe_gbp), 2) AS importe_gbp
FROM ventas -- Solo cantidades y precios positivos, sin C.
GROUP BY producto -- Reunimos códigos aunque cambie la descripción.
ORDER BY importe_gbp DESC, producto -- Mayor valor; empate por código.
LIMIT 5; -- Mostramos los cinco códigos de mayor valor de venta.
```

Resultado por valor de venta

Artículo o cargo (código)	unidades	importe_gbp
Cargo de envío DOTCOM (DOT)	706	206,248.77
Base para pastel Regency de 3 niveles (22423)	13,879	174,484.74
Manualidad de papel, pajarito (23843)	80,995	168,469.60
Portavelas de té colgante de corazón blanco (85123A)	37,660	104,518.80
Guirnalda de banderines para fiesta (47566)	18,295	99,504.33

Qué significa para las compras

Entre las dos listas solo coincide **Manualidad de papel, pajarito (23843)**. Las dos medidas dan listas diferentes. **DOT** suma **206,248.77 GBP** y está descrito como **Cargo de envío DOTCOM**. Corresponde a gastos de envío. No tendría sentido comprar más unidades de mercancía basándonos en ese primer lugar.

Para hacer una lista útil para compras, primero separaríamos artículos de gastos de envío y anotaciones manuales. Después revisaríamos cancelaciones y existencias. El siguiente caso muestra cómo puede cambiar una recomendación.

9. Una anomalía cambia la recomendación

Pregunta de negocio

Antes de recomendar la compra de más unidades del artículo Manualidad de papel, pajarito (23843), ¿qué nos dicen sus ventas y cancelaciones?

SQL y resultado

Consultamos `movimientos` para incluir las cancelaciones. `WHERE` conserva el código buscado. Las comillas lo tratan como texto. El orden temporal permite leer la secuencia, aunque no prueba una relación causal.

`SELECT` muestra el documento, la fecha, la cantidad, el precio y el valor de cada movimiento. `FROM movimientos` incluye ventas y cancelaciones, mientras que `WHERE` aísla el código 23843. `ORDER BY fecha, fila_origen` permite leer la secuencia temporal y usa la fila original para resolver empates. No sumamos aquí porque necesitamos inspeccionar los documentos.

Q13.

```
-- Elegimos documento, momento, unidades, precio y valor del renglón.  
SELECT factura, fecha, cantidad, precio_gbp, importe_gbp  
FROM movimientos -- Incluye cancelaciones, a diferencia de ventas.  
WHERE producto = '23843' -- Aislamos el código que queremos revisar.  
ORDER BY fecha, fila_origen; -- Secuencia temporal; desempate por fila.
```

factura	fecha	cantidad	precio_gbp	importe_gbp
581483	2011-12-09 09:15:00	80,995	2.08	168,469.60
C581484	2011-12-09 09:27:00	-80,995	2.08	-168,469.60

Hay **80,995 unidades en una venta y -80,995 en una cancelación**, ambas el 9 de diciembre de 2011. Juntas suman **0 unidades y 0.00 GBP**.

Qué significa y qué haríamos

No recomendaríamos a nuestro cliente comprar más de este artículo solo por su primer lugar. La lista inicial mostraba 80,995 unidades vendidas, pero al revisar sus dos movimientos encontramos que se compensan por completo. Agrupar y luego volver a los documentos evita recomendar compras a partir de una cifra incompleta.

Pediríamos al responsable de ventas que aclare estos documentos antes de incluir el artículo entre las compras prioritarias. Si hubiera pedidos vigentes y las existencias fueran insuficientes, entonces revisaríamos precio de compra y plazo de entrega para decidir cuánto pedir.

Las cantidades opuestas y la cercanía de las horas justifican investigar, pero no prueban la causa ni una relación formal entre los documentos. Para los demás artículos de la lista haríamos la misma revisión. No suponemos que tengan el mismo problema. En las páginas siguientes calculamos listas netas y frecuencia para cerrar la comparación.

10. Después de la anomalía · Unidades netas

¿Qué artículo queda primero al incluir las cancelaciones?

Para responder a nuestro cliente, distinguiremos tres criterios de popularidad. Primero sumamos las cantidades positivas y las negativas de documentos C, con precio positivo. **Son unidades netas registradas en el periodo**, no unidades físicas cuya entrega o devolución hayamos comprobado.

Antes separamos mercancías de cargos. Usamos el patrón de códigos de catálogo, añadimos ocho excepciones con mercancía identificable y apartamos cuatro códigos numéricos de vales, transporte, embalaje o naturaleza incierta. Los demás códigos fuera del patrón quedan separados. La regla y sus excepciones están escritas en SQL; `clasificacion-especiales.json` conserva la revisión y sus motivos.

SELECT muestra el código y SUM(cantidad) suma sus unidades con signo. FROM movimientos incluye ventas y cancelaciones. WHERE, AND y OR aplican los criterios de movimientos y mercancías. LENGTH revisa la longitud del código, SUBSTR separa su inicio y sufijo, y NOT GLOB descarta caracteres fuera del patrón. IN admite excepciones y NOT IN aparta cuatro códigos. GROUP BY calcula un neto por artículo. AS lo nombra, ORDER BY ... DESC prioriza el mayor neto y desempata por código, y LIMIT 5 muestra cinco artículos.

Q14.

```
-- Sumamos unidades con su signo para cada código.
SELECT producto, SUM(cantidad) AS unidades_netas
FROM movimientos -- Incluye ventas y cancelaciones.
WHERE precio_gbp > 0 -- No incluimos precios cero ni negativos.
  -- Aceptamos ventas positivas sin C o cantidades negativas con C.
  AND ((cancelacion = 0 AND cantidad > 0)
       OR (cancelacion = 1 AND cantidad < 0))
  AND ((
    -- Exigimos códigos de cinco a siete caracteres.
    LENGTH(producto) BETWEEN 5 AND 7
    -- Los cinco primeros caracteres deben ser dígitos.
    AND SUBSTR(producto, 1, 5) NOT GLOB '*[0-9]*'
    -- El sufijo, si existe, solo puede contener letras.
    AND SUBSTR(producto, 6) NOT GLOB '*[A-Za-z]*'
  ))
  -- Admitimos también estas ocho excepciones revisadas.
  OR producto IN (
    'DCGS0003', 'DCGS0004', 'DCGS0069', 'DCGS0070',
    'DCGS0076', 'DCGSSBOY', 'DCGSSGIRL', 'PADS'
  ))
  -- Apartamos cuatro códigos de cargos, vales o identidad incierta.
  AND producto NOT IN ('22016', '23444', '23574', '23702')
GROUP BY producto -- Calculamos una medida por código.
ORDER BY unidades_netas DESC, producto -- Mayor neto; empate por código.
LIMIT 5; -- Mostramos los cinco primeros códigos del criterio.
```

Resultado por unidades netas

Artículo o cargo (código)	unidades_netas
Recipiente para palomitas (22197)	56,450
Planeadores de la Segunda Guerra Mundial con diseños surtidos (84077)	53,847
Bolsa extragrande roja con lunares retro (85099B)	47,359
Adorno de pájaro de colores surtidos (84879)	36,381
Paquete de 72 capacillos para pastelito Retrospot (21212)	36,039

La respuesta por unidades netas es Recipiente para palomitas (22197), con 56,450.

El artículo 23843 queda con cero en este cálculo. Su gran registro positivo ya no encabeza la lista. Esto no demuestra que ambas facturas estén vinculadas formalmente ni que todas las cancelaciones correspondan a ventas del periodo.

El filtro produce una lista exploratoria de mercancías, no un catálogo certificado. Conservamos los códigos y no unimos artículos por descripciones parecidas. Identificar los productos más populares es un punto de partida para estudiar qué características comparten los artículos que más vende la empresa. Estas listas no identifican por sí solas esas características ni explican las preferencias de los compradores. Tampoco permiten decidir reposiciones sin información adicional, como inventario y pedidos vigentes.

11. Otra respuesta · Valor neto de ventas

¿Qué artículo aporta más valor de venta después de las cancelaciones?

Aplicamos exactamente los mismos filtros de mercancías y movimientos. Ahora sumamos cantidad * precio_gbp por código. Esta medida está en GBP; **no mide las utilidades**, porque no tenemos datos de costos.

SELECT muestra el código y SUM(importe_gbp) calcula su valor neto. ROUND redondea el total y AS lo nombra. FROM movimientos incluye cancelaciones. WHERE, AND y OR conservan los movimientos y mercancías definidos. LENGTH comprueba la longitud, SUBSTR separa partes del código y NOT GLOB aplica el patrón de caracteres. IN y NOT IN incorporan o apartan excepciones. GROUP BY reúne cada código. ORDER BY ... DESC ordena por valor neto, desempata por código y LIMIT 5 conserva los cinco primeros.

Q15.

```
-- Sumamos valores con signo; redondeamos solo el total.
SELECT producto, ROUND(SUM(importe_gbp), 2) AS valor_neto_gbp
FROM movimientos -- Incluye ventas y cancelaciones.
WHERE precio_gbp > 0 -- No incluimos precios cero ni negativos.
-- Aceptamos ventas positivas sin C o cantidades negativas con C.
AND ((cancelacion = 0 AND cantidad > 0)
     OR (cancelacion = 1 AND cantidad < 0))
AND ((
  -- Exigimos códigos de cinco a siete caracteres.
  LENGTH(producto) BETWEEN 5 AND 7
  -- Los cinco primeros caracteres deben ser dígitos.
  AND SUBSTR(producto, 1, 5) NOT GLOB '*[^0-9]*'
  -- El sufijo, si existe, solo puede contener letras.
  AND SUBSTR(producto, 6) NOT GLOB '*[^A-Za-z]*'
))
-- Admitimos también estas ocho excepciones revisadas.
OR producto IN (
  'DCGS0003', 'DCGS0004', 'DCGS0069', 'DCGS0070',
  'DCGS0076', 'DCGSSBOY', 'DCGSSGIRL', 'PADS'
))
-- Apartamos cuatro códigos de cargos, vales o identidad incierta.
AND producto NOT IN ('22016', '23444', '23574', '23702')
GROUP BY producto -- Calculamos una medida por código.
ORDER BY valor_neto_gbp DESC, producto -- Mayor valor; empate por código.
LIMIT 5; -- Mostramos los cinco primeros códigos del criterio.
```

Artículo o cargo (código)	valor_neto_gbp
Base para pastel Regency de 3 niveles (22423)	164,762.19
Guirnalda de banderines para fiesta (47566)	98,302.98
Portavelas de té colgante de corazón blanco (85123A)	97,894.50
Bolsa extragrande roja con lunares retro (85099B)	92,356.03
Luz nocturna de conejo (23084)	66,756.59

La respuesta por valor neto es Base para pastel Regency de 3 niveles (22423), con 164,762.19 GBP. DOT no participa porque representa envío. Al separar también otros cargos, vales y casos inciertos, podemos hablar de artículos dentro del alcance comercial definido, sin confundirlos con todos los conceptos facturados.

Un artículo puede generar mucho valor por su precio, aunque otro acumule más unidades. Para nuestro cliente, esta lista ayuda a priorizar dónde investigar margen y disponibilidad. No basta para decidir qué comprar ni cuánto ganaríamos. Las ventas generales del taller mantienen su alcance original. Este filtro adicional se aplica solo al análisis de popularidad de mercancías.

12. Una tercera respuesta · Presencia en facturas

¿Qué artículo aparece en más facturas de venta?

Contamos cada factura positiva una sola vez por código, aunque tenga varios renglones del mismo artículo. Se conserva el filtro de mercancías. **No contamos clientes distintos ni restamos documentos C al número de facturas de venta.**

FROM ventas usa solo ventas positivas. WHERE filtra mercancías combinando condiciones con AND y OR. LENGTH, SUBSTR y NOT GLOB revisan el patrón del código, mientras IN y NOT IN aplican las excepciones. GROUP BY producto reúne cada artículo. En SELECT, COUNT(DISTINCT factura) cuenta una vez cada documento que lo contiene y AS nombra esa frecuencia. ORDER BY ... DESC ordena de mayor a menor conteo, desempata por código y LIMIT 5 muestra los cinco primeros.

Q16.

```
-- Cada factura positiva cuenta una vez por artículo, aunque repita renglones.
-- No restamos facturas C ni interpretamos frecuencia como unidades netas.
-- DISTINCT evita repetir una factura con varios renglones del código.
SELECT producto, COUNT(DISTINCT factura) AS facturas_positivas
FROM ventas -- Solo ventas positivas sin C.
WHERE (
  (
    -- Exigimos códigos de cinco a siete caracteres.
    LENGTH(producto) BETWEEN 5 AND 7
    -- Los cinco primeros caracteres deben ser dígitos.
    AND SUBSTR(producto, 1, 5) NOT GLOB '*[^0-9]*'
    -- El sufijo, si existe, solo puede contener letras.
    AND SUBSTR(producto, 6) NOT GLOB '*[^A-Za-z]*'
  )
  -- Admitimos también estas ocho excepciones revisadas.
  OR producto IN (
    'DCGS0003', 'DCGS0004', 'DCGS0069', 'DCGS0070',
    'DCGS0076', 'DCGSSBOY', 'DCGSSGIRL', 'PADS'
  )
)
-- Apartamos cuatro códigos de cargos, vales o identidad incierta.
AND producto NOT IN ('22016', '23444', '23574', '23702')
GROUP BY producto -- Calculamos una medida por código.
-- Primero mayor número de facturas; desempatamos por código.
ORDER BY facturas_positivas DESC, producto
LIMIT 5; -- Mostramos los cinco primeros códigos del criterio.
```

Resultado por presencia en facturas

Artículo o cargo (código)	facturas_positivas
Portavelas de té colgante de corazón blanco (85123A)	2,198
Bolsa extragrande roja con lunares retro (85099B)	2,089
Base para pastel Regency de 3 niveles (22423)	1,988
Guirnalda de banderines para fiesta (47566)	1,685
Bolsa para almuerzo roja con lunares retro (20725)	1,565

La respuesta por frecuencia es Portavelas de té colgante de corazón blanco (85123A), presente en 2,198 facturas positivas. No llamamos a esta cifra frecuencia neta. Sin una relación comprobada entre documentos, restar facturas C supondría que anulan compras completas y podría descontar varias veces una misma venta.

Qué recomendamos al cliente

Cada criterio identifica un líder distinto, como muestran las tablas anteriores. **Cuatro artículos aparecen entre los cinco primeros por valor neto y por frecuencia.** Son Base para pastel Regency de 3 niveles (22423), Guirnalda de banderines para fiesta (47566), Portavelas de té colgante de corazón blanco (85123A) y Bolsa extragrande roja con lunares retro (85099B). Este último también figura entre los cinco primeros por unidades netas. La coincidencia en los tres criterios justifica investigarlo, sin convertirlo en el líder de todos.

Priorizaríamos revisar existencias, margen y pedidos vigentes de estos códigos. La recomendación de reponer dependería de esas comprobaciones. Ni la frecuencia de facturas demuestra retención de clientes ni estas cifras por sí solas predicen demanda futura.

13. Decisión 4 · Evolución de las ventas y patrones de tiempo

¿Cómo evolucionan las ventas y cuánto influyen los picos observados?

Primero miraremos la evolución y después los días y las horas. Usamos el valor neto registrado según nuestro criterio, con precio positivo, sumando ventas positivas sin C y cantidades negativas de documentos C. No mide las utilidades ni empareja cancelaciones con ventas concretas.

Tomamos semanas completas de lunes a domingo dentro de la cobertura del archivo. Se excluyen las semanas de borde del 29 de noviembre de 2010 y del 5 de diciembre de 2011. Quedan **52 semanas calendario, del 6 de diciembre de 2010 al 4 de diciembre de 2011**, pero solo **51 tienen registros**. La semana del 27 de diciembre al 2 de enero está ausente. Sus ventas quedan NULL, no cero.

WITH permite dividir una consulta en pasos con nombre que solo existen dentro del bloque. Aquí construiremos un calendario, resumiremos los registros y compararemos periodos.

Q17 resume cuatro bloques consecutivos de 13 semanas. No son trimestres calendario. El calendario generado conserva huecos y LEFT JOIN añade datos cuando existen. COUNT cuenta cobertura y SUM resume lo observado. El promedio divide entre semanas con registros. Q18, en `temporal-semanal.sql`, permite revisar el detalle semanal. Las dos consultas son independientes y no modifican la base.

WITH organiza pasos intermedios y RECURSIVE, junto con UNION ALL, genera los lunes sucesivos. SELECT elige campos y cálculos de cada paso, y FROM indica de dónde proceden. MIN y MAX localizan los extremos del periodo y DATE obtiene fechas o desplaza días. STRFTIME extrae el día de la semana, CAST lo convierte en entero, % calcula el resto y || une el texto con el que buscamos el lunes correspondiente.

WHERE, AND y las subconsultas de cobertura excluyen semanas incompletas. CASE WHEN distingue ventas, cancelaciones y documentos seleccionados. SUM acumula valores y COUNT(DISTINCT ...) cuenta fechas o facturas sin repetirlas. GROUP BY reúne primero semanas y después bloques de trece semanas. LEFT JOIN ... ON conserva los lunes sin datos. COALESCE convierte únicamente el conteo de días ausentes a cero, sin inventar ventas. ROW_NUMBER() OVER (ORDER BY ...) numera las semanas. Al final dividimos el neto entre semanas con registros, ROUND redondea las medidas, AS nombra las columnas y ORDER BY presenta los bloques cronológicamente.

Q17.

```
-- SUM resume sólo registros; no imputa la semana ausente ni mide estacionalidad.
-- WITH crea pasos locales; RECURSIVE permite generar el calendario.
WITH RECURSIVE cobertura AS (
  -- DATE quita la hora de los extremos del archivo completo.
  SELECT DATE(MIN(fecha)) AS primera_fecha,
         DATE(MAX(fecha)) AS ultima_fecha
  FROM movimientos
), periodos AS ( -- Construimos una fila por lunes.
  -- Buscamos el primer lunes en o después del inicio del archivo.
  SELECT DATE(primer_fecha, 'weekday 1') AS semana_inicio
  FROM cobertura
  UNION ALL -- Añadimos sucesivamente el lunes siguiente.
  SELECT DATE(semana_inicio, '+7 days') FROM periodos
  -- Solo añadimos otra semana si su domingo está dentro del archivo.
  WHERE DATE(semana_inicio, '+13 days') <=
        (SELECT ultima_fecha FROM cobertura)
), calendario AS ( -- Asignamos cada renglón a su lunes.
  -- %w da domingo=0; el ajuste calcula días transcurridos desde lunes.
  -- || une texto para restar esos días a la fecha del registro.
  SELECT *, DATE(fecha, '-' ||
    ((CAST(STRTIME('%w', fecha) AS INTEGER) + 6) % 7)
    || ' days') AS semana_inicio
  FROM movimientos
), agrupadas AS ( -- Resumimos solo semanas completas.
  -- El domingo está seis días después del lunes.
  SELECT semana_inicio, DATE(semana_inicio, '+6 days') AS semana_fin,
  -- Contamos fechas observadas distintas, no días de apertura.
  COUNT(DISTINCT DATE(fecha)) AS dias_con_registros,
  -- CASE aporta el valor solo si cumple el filtro de ventas.
  SUM(CASE WHEN cancelacion = 0 AND cantidad > 0 AND precio_gbp > 0
    THEN importe_gbp ELSE 0 END) AS ventas_positivas,
  -- Sumamos cancelaciones con signo negativo y precio positivo.
  SUM(CASE WHEN cancelacion = 1 AND cantidad < 0 AND precio_gbp > 0
    THEN importe_gbp ELSE 0 END) AS cancelado_negativo,
  -- Una factura de venta cuenta una vez; los otros casos dan NULL.
  COUNT(DISTINCT CASE
    WHEN cancelacion = 0 AND cantidad > 0 AND precio_gbp > 0
    THEN factura END) AS facturas_ventas
  FROM calendario
  -- Excluimos la semana inicial si empezó antes del archivo.
  WHERE semana_inicio >= (SELECT primera_fecha FROM cobertura)
  -- Excluimos la última si su domingo queda después del archivo.
  AND DATE(semana_inicio, '+6 days') <=
    (SELECT ultima_fecha FROM cobertura)
  GROUP BY semana_inicio -- Un grupo por cada lunes.
), semanas AS ( -- Conservamos también las semanas sin registros.
  SELECT periodos.semana_inicio,
         DATE(periodos.semana_inicio, '+6 days') AS semana_fin,
  -- Solo los días ausentes pasan a cero; ventas siguen en NULL.
  COALESCE(agrupadas.dias_con_registros, 0) AS dias_con_registros,
  agrupadas.ventas_positivas, agrupadas.cancelado_negativo,
  agrupadas.facturas_ventas
  -- LEFT JOIN mantiene cada lunes, aunque no encuentre datos.
  FROM periodos LEFT JOIN agrupadas
    ON periodos.semana_inicio = agrupadas.semana_inicio
), numeradas AS ( -- Numeramos semanas, incluidas las no observadas.
  SELECT *, ROW_NUMBER() OVER (ORDER BY semana_inicio) AS numero_semana
  FROM semanas
)
-- Numeramos bloques consecutivos de 13 semanas; no son trimestres.
```

```

SELECT CAST((numero_semana - 1) / 13 AS INTEGER) + 1 AS bloque,
-- Extremos y número de semanas del calendario de cada bloque.
MIN(semama_inicio) AS desde, MAX(semama_fin) AS hasta,
COUNT(*) AS semanas,
-- Cada semana observada aporta 1; una semana sin registros aporta 0.
SUM(CASE WHEN dias_con_registros > 0 THEN 1 ELSE 0 END)
AS semanas_con_registros,
SUM(dias_con_registros) AS dias_con_registros, -- Fechas observadas.
-- SUM omite NULL: resume lo registrado, sin estimar lo ausente.
ROUND(SUM(ventas_positivas), 2) AS ventas_positivas,
ROUND(SUM(cancelado_negativo), 2) AS cancelado_negativo,
-- El neto suma ventas y cancelaciones ya negativas.
ROUND(SUM(ventas_positivas + cancelado_negativo), 2) AS neto,
SUM(facturas_ventas) AS facturas_ventas, -- Documentos seleccionados.
-- Dividimos por semanas con registros, no por las 13 del calendario.
ROUND(SUM(ventas_positivas + cancelado_negativo) /
SUM(CASE WHEN dias_con_registros > 0 THEN 1 ELSE 0 END), 2)
AS neto_medio_por_semana_con_registros
FROM numeradas
-- Agrupamos con la misma regla usada para asignar el número de bloque.
GROUP BY CAST((numero_semana - 1) / 13 AS INTEGER)
ORDER BY bloque; -- Del bloque más antiguo al más reciente.

```

Qué muestra la evolución semanal

Bloque y periodo	Semanas con registros	Días con registros	Neto GBP	Media por semana registrada
1 · 2010-12-06 a 2011-03-06	12/13	69	1;733,854.56	144,487.88
2 · 2011-03-07 a 2011-06-05	13/13	72	1;886,090.39	145,083.88
3 · 2011-06-06 a 2011-09-04	13/13	77	2;078,323.46	159,871.04
4 · 2011-09-05 a 2011-12-04	13/13	78	3;589,151.17	276,088.55

Los valores registrados son mayores hacia el final del periodo, pero no crecen de forma uniforme. Los bloques iniciales tienen medias próximas a 144,488 y 145,084 GBP por semana registrada. El tercero llega a 159,871 y el último a 276,089. La cobertura cambia de 69 a 78 días entre el primero y el último. Ni sumar ni promediar elimina por completo esa diferencia.

Una comparación reciente tiene cobertura más parecida. Del **7 de noviembre al 4 de diciembre** se registran **1,355,027.72 GBP netos**, frente a **996,405.82 GBP** del **10 de octubre al 6 de noviembre**. Son cuatro semanas y 24 días con registros en cada grupo, con un aumento de **35.99 %**. El pico semanal es el **14-20 de noviembre, con 380,407.57 GBP**. Esto describe un tramo de aumento y picos observados, no demuestra crecimiento sostenido ni su causa. La cercanía de Navidad es una hipótesis que requeriría más años y datos de promociones, precios y catálogo. Aproximadamente un año no permite confirmar una estacionalidad anual que se repita.

Recomendamos comprobar pedidos pendientes, retrasos y capacidad antes de ampliar recursos. Un día sin registros no prueba cierre ni ventas reales cero. Las medias por día u hora que siguen describen el patrón observado. No sustituyen esta evolución.

Contraste con meses completos

La consulta mensual de consultas.sql usa substr(fecha, 1, 7) y suma las ventas **positivas**, sin C y con cantidad y precio positivos. Es una medida distinta del neto semanal anterior, que incorpora cancelaciones.

FROM ventas mantiene las ventas positivas. En SELECT, SUBSTR(fecha, 1, 7) extrae el año y el mes. GROUP BY reúne los renglones con ese mismo año-mes y SUM suma su valor. ROUND redondea cada total y AS nombra las columnas. ORDER BY mes coloca los periodos en orden cronológico. El cálculo no convierte diciembre de 2011 en un mes completo.

Q19.

```
-- SUBSTR toma año y mes: los siete primeros caracteres de fecha.  
SELECT substr(fecha, 1, 7) AS mes,  
       -- Sumamos ventas positivas; no restamos cancelaciones aquí.  
       ROUND(SUM(importe_gbp), 2) AS valor_ventas_gbp  
FROM ventas -- Documentos sin C, cantidad y precio positivos.  
GROUP BY substr(fecha, 1, 7) -- Un total por cada año-mes.  
ORDER BY mes; -- Orden cronológico; diciembre de 2011 es parcial.
```

Mes	Ventas positivas GBP	Cobertura
2011-10	1;154,979.30	Mes completo
2011-11	1;509,496.33	Mes completo
2011-12	638,792.68	Hasta el día 9

El valor de las ventas positivas aumenta de octubre a noviembre **30.69 %**, calculado como $100 \times (\text{noviembre} / \text{octubre} - 1)$. Diciembre de 2011 termina el día 9; no permite concluir una caída frente a noviembre completo.

El aumento puede reflejar precios o mezcla de artículos, no el mismo porcentaje de trabajo adicional. Si también crecen los pedidos y los retrasos, valoraríamos un refuerzo temporal con datos de personal, tiempos y costos. La consulta completa y todos los meses quedan en los recursos.

Días y horas dentro de esa evolución

Pregunta de negocio

¿A qué horas se registran más facturas? ¿Son también las horas con mayor valor medio por factura?

SQL y resultado

Si una factura tiene varias marcas de tiempo, MIN(fecha) la asigna a la fecha y hora más temprana de sus renglones seleccionados. Así no la contamos dos veces.

WITH facturas AS crea un resultado intermedio para esta consulta. Allí FROM ventas toma los renglones positivos, GROUP BY factura reúne cada documento, MIN(fecha) fija su primera marca de tiempo y SUM calcula su valor. En el segundo SELECT, STRFTIME extrae la hora. COUNT(*) cuenta documentos ya agrupados, SUM calcula ventas y AVG el valor medio por factura. ROUND redondea y AS nombra las medidas. El último GROUP BY reúne horas iguales y ORDER BY las presenta cronológicamente.

Q20.

```
WITH facturas AS ( -- Resultado intermedio válido en este bloque.
  -- MIN asigna cada documento a su primera fecha y hora registrada.
  SELECT factura, MIN(fecha) AS fecha,
    SUM(importe_gbp) AS valor_gbp -- Valor total del documento.
  FROM ventas -- Solo los renglones de ventas positivas.
  GROUP BY factura -- Una fila por documento, no por renglón.
)
SELECT strftime('%H', fecha) AS hora, -- Extraemos la hora: 00 a 23.
  COUNT(*) AS facturas, -- Ahora cada fila es una factura.
  ROUND(SUM(valor_gbp), 2) AS ventas_gbp, -- Valor por hora.
  ROUND(AVG(valor_gbp), 2) AS media_gbp -- Media por factura.
FROM facturas -- Usamos el resultado intermedio ya agregado.
GROUP BY hora -- Reunimos documentos de una misma hora.
ORDER BY hora; -- Ordenamos de la primera hora a la última.
```

Hora	Facturas	Ventas GBP	GBP/factura
06	1	4.25	4.25
07	29	31,059.21	1,071.01
08	566	283,868.52	501.53
09	1,484	990,267.82	667.30
10	2,361	1;446,742.70	612.77
11	2,396	1;239,981.79	517.52
12	3,219	1;444,218.53	448.65
13	2,753	1;265,736.30	459.77
14	2,457	1;181,812.37	481.00
15	2,336	1;352,972.18	579.18
16	1,335	754,006.56	564.80
17	667	461,603.49	692.06
18	192	144,813.05	754.23
19	146	50,665.01	347.02
20	18	18,932.76	1,051.82

Las cancelaciones no se incluyen en este conteo de facturas de venta.

La hora con más facturas no tiene la mayor media. Las 12 concentran más facturas, pero la mayor media observada corresponde a las 07, con 1,071.01 GBP y solo 29 facturas. No conviene elegir un horario únicamente por esa media.

14. También importa el día de la semana

Pregunta de negocio

¿Qué días se registran más facturas y cómo cambia el valor medio?

SQL y resultado

Conservamos la misma agrupación por factura y cambiamos hora por día. `strftime('%w', fecha)` devuelve 0 para domingo, 1 para lunes y así hasta 6 para sábado. Dividimos entre las fechas con registros de ventas para no comparar solo los totales de días que aparecen diferente número de veces. `GBP/factura` es ventas divididas entre documentos, no entre renglones ni clientes. Las dos tablas reparten las mismas 19,960 facturas, cada una una sola vez.

`WITH` reúne primero cada factura de ventas mediante `GROUP BY`. `MIN` conserva su primera fecha y `SUM` su valor. Después `SELECT` usa `STRFTIME` para obtener el día de la semana. `COUNT(*)` cuenta facturas y `COUNT(DISTINCT DATE(fecha))` cuenta fechas diferentes sin la hora. Su cociente calcula facturas por fecha observada, con `1.0` para conservar decimales. `SUM` obtiene ventas, `AVG` la media por factura, `ROUND` redondea y `AS` nombra los resultados. El último `GROUP BY` reúne días de la semana y `ORDER BY` sigue sus códigos de domingo a sábado.

Q21.

```
WITH facturas AS ( -- Primero evitamos contar renglones como facturas.
  SELECT factura, MIN(fecha) AS fecha, -- Primera fecha del documento.
         SUM(importe_gbp) AS valor_gbp -- Sumamos sus renglones.
  FROM ventas -- Ventas positivas, sin documentos C.
  GROUP BY factura -- Una fila por documento seleccionado.
)
SELECT strftime('%w', fecha) AS dia, -- Domingo = 0; sábado = 6.
       COUNT(*) AS facturas, -- Contamos documentos, no clientes.
       -- DATE quita la hora; DISTINCT cuenta fechas diferentes.
       COUNT(DISTINCT date(fecha)) AS fechas,
       -- Dividimos por fechas con ventas, no por días de apertura.
       -- 1.0 fuerza división decimal; ROUND deja dos decimales.
       ROUND(1.0 * COUNT(*) /
            COUNT(DISTINCT date(fecha)), 2) AS por_fecha,
       ROUND(SUM(valor_gbp), 2) AS ventas_gbp, -- Valor del grupo.
       ROUND(AVG(valor_gbp), 2) AS media_gbp -- Media por factura.
FROM facturas -- Partimos de los documentos ya agregados.
GROUP BY dia -- Reunimos el mismo día de la semana entre fechas.
ORDER BY dia; -- Seguimos los códigos 0 a 6, no el volumen.
```

Día	Facturas	Fechas	Por fecha	Ventas GBP	GBP/factura
Domingo	2,204	50	44.08	813,827.61	369.25
Lunes	3,126	47	66.51	1,779,575.04	569.28
Martes	3,554	52	68.35	2,178,632.61	613.01
Miércoles	3,690	53	69.62	1,851,147.81	501.67
Jueves	4,246	53	80.11	2,203,161.24	518.88
Viernes	3,140	50	62.80	1,840,340.23	586.10

No hay registros de sábados, ni siquiera antes de aplicar el filtro de ventas. El periodo contiene 53 sábados, pero no sabemos si la empresa cerraba, si no registraba operaciones ese día o si falta información. No los tratamos como 53 días abiertos con cero ventas. Las otras fechas ausentes tampoco prueban cierres.

15. De los horarios a una prueba de promoción

Dos hallazgos

Más facturas no significa una factura media mayor. De 12:00 a 12:59 hay **3,219 facturas** y una media de **448.65 GBP**. De 10:00 a 10:59 hay **2,361 facturas**, pero la media es **612.77 GBP**. Las ventas totales son muy próximas, 1;444,218.53 y 1;446,742.70 GBP respectivamente. Hay registros en 305 fechas para las 12 y en 303 para las 10. El pico de facturas de las 12 aparece en los doce meses completos, con empate en diciembre de 2010. **Los días tampoco son iguales.** Los jueves registran **80.11 facturas por fecha con ventas**, frente a **44.08 los domingos**. La media por factura es **518.88 GBP** el jueves y **369.25 GBP** el domingo. Los promedios describen fechas con registros, no todos los días que la tienda estuvo abierta.

Una propuesta que podemos probar

El mediodía reúne muchas facturas de menor valor medio que las de las 10. **Proponemos probar una promoción de artículos complementarios de 12:00 a 12:59**, si hay existencias y el margen permite la oferta. La hipótesis es aumentar el valor de la compra, no que la promoción vaya a funcionar por haber más facturas. No ofrecemos descuentos generales solo por coincidir con una hora concurrida.

Compararíamos periodos con y sin promoción, asignados al azar dentro del mismo día de la semana y fechas comparables. No compararíamos un jueves con oferta contra un domingo sin ella. Mediríamos facturas, valor medio, cancelaciones y margen después del descuento. Revisaríamos también el total del día para saber si solo desplazamos compras desde otras horas. Harán falta costos y un registro de la promoción para evaluar si compensa.

Qué debemos confirmar antes

UCI describe la hora de generación de la transacción. **No demuestra cuándo el comprador eligió los artículos ni en qué hora local estaba.** No hay zona horaria documentada. Antes de programar la prueba, hay que confirmar cómo se registra la hora y el horario real de atención. Muchos clientes del negocio original eran mayoristas. Pedidos grandes o registros por lotes podrían influir. La base sin CustomerID no permite separar ese efecto por cliente.

La auditoría encuentra fechas válidas en los 541,909 renglones y 305 fechas con registros. Hay 42 facturas seleccionadas con dos marcas de tiempo, una de ellas en dos horas. Los picos de las 12 y del jueves se mantienen sin diciembre de 2011 parcial y al limitar a Reino Unido. Las cancelaciones se revisan por separado, sin atribuirles a la hora de la venta original. Estos controles apoyan el patrón observado, pero **no demuestran el efecto de una promoción.**

16. Entregable · Diagnóstico para nuestro cliente

Pregunta de negocio

¿Cuáles son los hallazgos más relevantes para nuestro cliente? ¿Qué le recomendamos hacer a partir de cada uno y qué falta comprobar? Como consultores, reunimos mercados, artículos y evolución temporal en una nota con recomendaciones condicionales y límites explícitos. El siguiente ejemplo reúne tres conclusiones. Es una síntesis del análisis, no un límite al número de hallazgos que podemos identificar.

Diagnóstico para el cliente

Revisamos **541,909 renglones**, del 1 de diciembre de 2010 al 9 de diciembre de 2011. Las ventas seleccionadas suman **10;666,684.54 GBP** antes de cancelaciones y **9;769,872.05 GBP** después de incluirlas según nuestro criterio. Son valores de venta, no utilidades ni cobros comprobados.

1. La mayor parte de las ventas depende del Reino Unido

Hallazgo. Reino Unido aporta **84.61 %** de las ventas seleccionadas (Q8). Una caída allí afectaría a gran parte del negocio. **Recomendamos** calcular distintos escenarios de caída para decidir qué gastos o compras ajustar. Países Bajos e Irlanda son dos opciones para estudiar crecimiento, pero una campaña pequeña requeriría comprobar costos de envío, márgenes y capacidad de atención. Las ventas actuales no prueban la rentabilidad de una expansión.

2. La prioridad de compras cambia según la medida

Hallazgo. Las unidades netas, el valor neto y la presencia en facturas identifican líderes distintos. Bolsa extragrande roja con lunares retro (85099B) está entre los cinco primeros con los tres criterios. El caso de 23843 y los cargos DOT muestran por qué una lista inicial no basta para comprar. **Recomendamos** revisar estos candidatos con existencias, pedidos vigentes, costos y plazos. La frecuencia no cuenta clientes y las ventas no miden las utilidades; ninguna lista demuestra por sí sola cuánto conviene reponer.

3. El aumento reciente requiere comprobar capacidad

Hallazgo. El neto de las cuatro semanas del 7 de noviembre al 4 de diciembre supera en **35.99 %** al de las cuatro anteriores, con igual número de días registrados. Las medias de los bloques crecen al final, pero hay picos y un hueco de cobertura. El patrón horario ofrece momentos para probar promociones, no una explicación del crecimiento. **Recomendamos** revisar retrasos y pedidos pendientes antes de ampliar recursos; si hay margen y existencias, probar artículos complementarios con un periodo de comparación equivalente. Un año no confirma estacionalidad anual, diciembre está incompleto y no conocemos las causas de cancelación ni de cada pico.

El diagnóstico debe explicar a nuestro cliente **qué encontramos, por qué importa y qué le recomendamos hacer**. Cada recomendación debe dejar claro qué falta comprobar. Las extensiones siguientes son independientes y permiten profundizar según la decisión del cliente.

17. Extensión · Revisar la calidad

Pregunta del cliente

Nuestro cliente propone borrar todos los renglones sin descripción o con precio igual o menor que cero. ¿Qué información perderíamos y cómo podría afectar al análisis?

SQL y resultado

Contamos por separado los renglones sin descripción y los que tienen precio igual o menor que cero. La primera consulta usa `IS NULL` para detectar un valor ausente; `= NULL` no sirve para esa comparación. La segunda busca precios iguales o menores que cero. Un precio cero es un valor registrado, no un vacío.

`FROM lineas` revisa el archivo completo. `WHERE descripcion IS NULL` conserva los renglones cuyo nombre está ausente. `SELECT COUNT(*)` cuenta esa selección y `AS` llama al resultado `sin_descripcion`. No contamos textos vacíos ni borramos registros.

```
SELECT COUNT(*) AS sin_descripcion -- Cuenta los renglones del filtro.
FROM lineas -- Revisamos todos los registros, no solo ventas.
WHERE descripcion IS NULL; -- IS NULL detecta ausencia, no texto vacío.
```

`FROM lineas` vuelve a tomar el archivo completo, sin depender de la consulta anterior. `WHERE precio_gbp <= 0` conserva precios cero y negativos. `SELECT COUNT(*)` cuenta esos renglones y `AS` nombra el resultado. Este grupo puede coincidir parcialmente con el de descripciones ausentes.

```
SELECT COUNT(*) AS precio_no_positivo -- Cuenta renglones del filtro.
FROM lineas -- No borramos ni corregimos estos registros.
WHERE precio_gbp <= 0; -- Incluye cero y precios negativos.
```

sin_descripcion
1,454

precio_no_positivo
2,517

Hay **1,454 renglones sin descripción** y **2,517 con precio no positivo**. Los grupos pueden solaparse. Sumar estos conteos no daría necesariamente el número de filas diferentes que borraríamos.

Interpretación y recomendación

Una descripción ausente no obliga a descartar el renglón si conserva un código útil para agrupar. El criterio de ventas excluye precios no positivos del cálculo de ventas, pero sus datos siguen en `lineas` para revisarlos. No podemos deducir que cada cero sea un regalo o un error. Conservaríamos los datos originales y explicaríamos qué renglones dejamos fuera de cada cálculo. Borrarlos impediría volver a revisar qué ocurrió. La consulta de cantidades negativas sin marca de cancelación, incluida en `consultas.sql`, permite completar la auditoría.

18. Extensión · Un código, dos nombres

Pregunta del cliente

Marketing encuentra dos descripciones para el código 85123A. ¿Debemos contar sus ventas juntas o por separado? ¿Qué necesitamos comprobar en el catálogo?

SQL y resultado

Inspeccionamos las descripciones que aparecen con ese código en la vista `ventas`. Agrupamos por código y descripción para poder ver cada combinación. `COUNT(*)` indica cuántos renglones usan cada texto, no cuántas unidades se vendieron.

`FROM ventas` usa el criterio de ventas positivas y `WHERE` aísla el código 85123A. `GROUP BY` `producto`, `descripcion` separa sus combinaciones de código y texto. `SELECT` muestra cada combinación junto con `COUNT(*)`, que cuenta sus renglones, no sus unidades. `AS lineas` nombra el conteo. `ORDER BY ... DESC` coloca primero la descripción más frecuente y desempata alfabéticamente.

```
-- Elegimos código y texto, y contamos cuántos renglones los usan.  
SELECT producto, descripcion, COUNT(*) AS lineas  
FROM ventas -- Conservamos el criterio de ventas positivas.  
WHERE producto = '85123A' -- Revisamos un único código.  
GROUP BY producto, descripcion -- Separamos cada variante de texto.  
ORDER BY lineas DESC, descripcion; -- Primero la más frecuente.
```

producto	descripcion	lineas
85123A	Portavelas de té colgante de corazón blanco	2,256
85123A	Portavelas de té colgante de corazón color crema	9

En las ventas seleccionadas aparecen **2 descripciones** para el mismo código. El texto más frecuente aparece en **2,256 renglones** y el otro en **9**. Hay dos descripciones asociadas al mismo código, una blanca y otra crema. Los registros no permiten decidir por sí solos si corresponden al mismo artículo, a variantes o a un error.

Interpretación y recomendación

En el resumen sumaríamos juntas las ventas del mismo código `producto`. Después comprobaríamos en el catálogo si ambas descripciones se refieren al mismo artículo o si hubo un cambio que deba explicarse. No elegimos automáticamente un nombre como el correcto ni cambiamos el original sin evidencia adicional.

Tampoco añadimos una descripción sin agruparla o decidir cómo seleccionarla. SQLite puede aceptar una consulta ambigua y mostrar un texto que no representa a todo el grupo. Una presentación comercial debería verificar el nombre contra un catálogo autorizado antes de usarlo en una promoción.

19. Extensión · Transferir y comprobar las consultas

Francia · ¿Una lista de ventas basta para comprar?

Filtramos ventas por Francia, agrupamos por código y sumamos unidades y valor. Las consultas de artículos y total de Francia en `consultas.sql` permiten comparar los tres primeros con todo el país.

Artículo o cargo (código)	unidades	importe_gbp
Gastos de envío (POST)	825	15,454.00
Manual (M)	6	9,492.37
Luz nocturna de conejo (23084)	4,024	7,277.20

Entre esos códigos figuran POST, de envío, y M, manual. Revisaríamos esos registros y separaríamos los cargos antes de recomendar mercancía. El total nacional incluye más códigos. El valor de venta no informa margen ni existencias.

Finanzas · ¿Cómo comprobar el balance en una consulta?

La consulta de ventas, cancelaciones y balance de `consultas.sql` reproduce el resultado presentado al elegir la cifra de ventas. UNION ALL coloca las tres sumas una debajo de otra; OR reúne ventas y cancelaciones y los paréntesis mantienen el precio positivo en ambos grupos. Se suma una vez el valor negativo. Los grupos son excluyentes, pero no emparejan documentos ni prueban que una cancelación corresponda a una venta positiva del mismo periodo.

Logística · ¿Una muestra revela todo el trabajo?

Las consultas de logística de `consultas.sql` cuentan renglones de Francia en `lineas`, con precio positivo y cantidades de al menos 10 o 20 unidades.

El conteo pasa de **4,664 a 1,614 renglones**, aunque las dos listas con LIMIT 5 muestran los mismos cinco.

LIMIT recorta lo visible, no el conjunto. Entregaríamos lista y conteo, y estimaríamos tiempo de revisión y problemas que podrían quedar fuera antes de elegir el umbral. Se cuentan renglones, no pedidos ni paquetes. No se calcula valor comercial. Todas las consultas completas y resultados están en los recursos.

20. Extensión · Dónde se concentra el valor cancelado

Pregunta del cliente y método

¿Qué países recomendaríamos a nuestro cliente investigar por sus cancelaciones?

Comparamos el valor absoluto y su proporción respecto de las ventas positivas del mismo país. Trabajamos con todo el periodo, del 1 de diciembre de 2010 al 9 de diciembre de 2011, incluido el último mes parcial.

El numerador es el **valor absoluto de la suma cancelada**, con prefijo C, cantidad negativa y precio positivo. El denominador suma los renglones sin C, con cantidad y precio positivos. La proporción es $100 * \text{numerador} / \text{denominador}$. La consulta de países de cancelaciones.sql calcula también unidades y documentos distintos de cada grupo. NULLIF devuelve NULL si el denominador es cero. No significa una proporción de cero.

SQL y resultado

La tabla muestra los cinco países con mayor valor cancelado, sin ocultar los casos con pocas facturas. Los documentos C se cuentan aparte de las ventas.

País	GBP cancelados	% del valor positivo	Docs venta	Docs C
Reino Unido	815,291.60	9.03	18,019	3,372
Irlanda	20,177.14	7.12	288	72
Francia	12,311.21	5.87	392	69
Singapur	12,158.90	57.14	7	3
Alemania	7,168.93	3.13	457	146

Interpretación y recomendación

Reino Unido concentra el mayor valor cancelado, pero también la mayor actividad comercial. Conviene empezar allí una revisión de documentos por su magnitud económica. Eso no demuestra que su proceso funcione peor.

Para comparar proporciones con algo más de respaldo, aplicamos un criterio de exploración de **al menos 100 documentos de ventas y 20 de cancelación**. No es una garantía estadística. Lo cumplen Reino Unido, Irlanda, Francia y Alemania. Entre ellos, Reino Unido registra 9.03 % y Alemania 3.13 %.

Singapur presenta **57.14 %**, pero solo tiene **7 documentos de ventas y 3 de cancelación**. Antes de priorizar una intervención general, revisaríamos esos pocos documentos, los cargos y su relación con las ventas originales.

Acción condicional. Si la revisión revela un problema repetido y corregible en pedidos o registros, probaríamos una mejora y mediríamos su efecto. Harían falta motivos de cancelación, documentos vinculados y costos para decidirla.

Límite. Esta proporción de valores no es una tasa de devolución ni el porcentaje de facturas originales canceladas. Las cancelaciones pueden remitir a ventas de otro periodo. Cambios en precios, cargos o composición del pedido también afectan la comparación. No conocemos las causas a partir de estos datos.

21. Extensión · Qué códigos revisar por cancelaciones

Pregunta del cliente

¿Qué códigos justifican revisar mercancía, cargos o registros?

SQL y resultado

Periodo completo del 01/12/2010 al 09/12/2011. Cancelaciones con prefijo C, cantidad negativa y precio positivo. Ventas sin C, con cantidad y precio positivos. Por código, ordenamos los GBP cancelados absolutos y comparamos proporciones sobre valor positivo y documentos.

Artículo o cargo (código)	GBP cancelados	% del valor positivo	Docs venta	Docs C
Comisión de Amazon (AMAZONFEE)	235,281.59	1,709.76	2	32
Manualidad de papel, pajarito (23843)	168,469.60	100.00	1	1
Manual (M)	146,784.46	187.92	289	223
Frasco mediano de almacenamiento con tapa de cerámica (23166)	77,479.64	94.83	247	10
Gastos de envío (POST)	11,871.24	15.20	1,126	124

Interpretación y límites

Comisión de Amazon (AMAZONFEE), un cargo, encabeza la tabla. M es manual y POST incluye envío. Superar 100 % indica cancelaciones mayores al valor positivo del periodo. No mide pedidos emparejados.

Manualidad de papel, pajarito (23843) tiene un documento positivo y uno C, ambos de 168,469.60 GBP en magnitud. Revisaríamos ese extremo sin asumir que sea habitual. Hay **16 códigos con valor cancelado y sin ventas positivas**, como CRUK y D; su proporción es NULL. `cancelaciones.sql` muestra sus descripciones y documentos.

Dos artículos con más documentos para investigar

Seleccionamos mercancías con al menos **100 documentos positivos y 20 C**. El umbral evita casos escasos. No elimina sesgos ni empareja ventas y cancelaciones.

Artículo (código)	GBP positivos	GBP cancelados	% valor	% unidades	Docs venta / C
Portavelas de té de estrella de vidrio de color [variante D0876] (71477)	20,658.56	3,443.62	16.67	18.19	316 / 31
Base para pastel Retrospect roja (21843)	21,365.25	2,480.50	11.61	16.00	539 / 42

Portavelas de té de estrella de vidrio de color [variante D0876] (71477) es un portavelas de vidrio de estrella; Base para pastel Retrospect roja (21843), una base para pastel. Agrupamos por código ante descripciones variables. En el portavelas, **16.67 % por valor y 18.19 % por unidades** difieren. Precios y composición afectan la proporción monetaria.

Recomendación condicional. Antes de reponer, revisaríamos documentos, motivos, precios y estado de los pedidos. Si se confirma un problema repetido, evaluaríamos medidas con compras u operaciones, sin atribuir defectos, devoluciones físicas ni responsabilidad al proveedor. No sumamos los conteos por código para obtener el total de facturas. Una misma factura puede contener varios artículos.

22. Extensión · Qué países compran más unidades por factura

Pregunta del cliente

¿En qué mercados convendría revisar capacidad de preparación y condiciones para pedidos grandes? Usamos todo el periodo, del 1 de diciembre de 2010 al 9 de diciembre de 2011, y solo los renglones de ventas, sin C, cantidad positiva y precio positivo. Primero sumamos unidades por país y factura. En este archivo cada factura seleccionada pertenece a un solo país.

Primer paso para reunir unidades por factura

FROM ventas toma los renglones positivos. GROUP BY pais, factura reúne los de cada factura y país. SELECT muestra ambos identificadores y SUM(cantidad) calcula sus unidades conjuntas. AS unidades nombra el resultado. Este primer paso todavía no calcula medias, medianas ni una clasificación.

```
-- Una fila por factura y país, aunque haya muchos renglones.  
-- Elegimos país y factura; SUM reúne las unidades del documento.  
SELECT pais, factura, SUM(cantidad) AS unidades  
FROM ventas -- Solo renglones positivos sin C.  
GROUP BY pais, factura; -- Un total por documento y país.
```

Resultado de la consulta completa

La consulta de países de tamaño-pedidos.sql añade la media, la mediana y el número de facturas. La mediana es el valor central de las cantidades ordenadas. Para un número par promedia los dos centrales. La media es unidades totales divididas entre facturas.

Mostramos los cinco primeros por media entre países con **al menos 50 facturas**, y Reino Unido como referencia. El umbral es un criterio exploratorio para evitar comparar mercados con solo unos pedidos. No asegura representatividad.

País	Facturas	Media unidades	Mediana unidades	Máximo
Países Bajos	94	2,131.50	442.00	14,730
Australia	57	1,471.95	214.00	15,049
Suiza	54	567.20	298.00	3,142
Irlanda	288	511.02	307.00	6,198
España	90	310.44	223.00	1,506
Reino Unido	18,019	258.75	146.00	80,995

Interpretación y recomendación

Países Bajos tiene **94 facturas**, con media de **2,131.50 unidades** y mediana **442**. En Reino Unido son **18,019 facturas**, media **258.75** y mediana **146**. El primer mercado combina menos documentos y pedidos mayores. No concluiríamos lo mismo contando solo renglones o mirando ventas en GBP.

Acción condicional. Si los pedidos grandes requieren más preparación, revisaríamos capacidad, embalaje y condiciones logísticas para Países Bajos. Antes de cambiar mínimos o descuentos, pediríamos costos por pedido, volumen, peso, plazos y margen. Muchas unidades no prueban por sí solas que un comprador sea mayorista ni permiten contar clientes diferentes. La distancia entre media y mediana revela la influencia de pedidos grandes. Las unidades incluyen códigos de cargos y ajustes que pasan el filtro. No representan necesariamente piezas físicas equivalentes ni horas de trabajo. El máximo británico incluye Manualidad de papel, pajarito (23843). Revisar cancelaciones y composición del pedido sigue siendo necesario antes de recomendar recursos.

23. Extensión · Qué artículos se compran en lotes mayores

Pregunta del cliente

¿Qué artículos podrían requerir revisar lotes, embalajes o reposición? Analizamos todo el periodo, del 1 de diciembre de 2010 al 9 de diciembre de 2011. Usamos ventas, con renglones sin C y cantidad y precio positivos. Cada factura cuenta una vez por código, aunque lo repita en varios renglones.

Primer paso para reunir unidades por factura

FROM ventas toma los renglones positivos. GROUP BY producto, factura reúne los de cada factura y artículo. SELECT muestra ambos identificadores y SUM(cantidad) calcula sus unidades conjuntas. AS unidades nombra el resultado. Este primer paso todavía no calcula medias, medianas ni una clasificación.

```
-- Una fila por código y factura que contiene ese código.  
-- Elegimos código y factura; SUM reúne sus unidades dentro de ella.  
SELECT producto, factura, SUM(cantidad) AS unidades  
FROM ventas -- Mismo filtro positivo.  
GROUP BY producto, factura; -- Reúne renglones repetidos del código.
```

Resultado de la consulta completa

La consulta de artículos de tamaño-pedidos.sql calcula después media y mediana de esas cantidades. No divide entre todas las facturas de la tienda ni cuenta clientes. Para la comparación mostramos los cinco primeros por media con **al menos 100 facturas que contienen el código**. Es un criterio exploratorio de frecuencia, no una prueba estadística.

Artículo (código)	Facturas con código	Media unidades	Mediana unidades	Máximo
Frasco mediano de almacenamiento con tapa de cerámica (23166)	247	315.92	9.00	74,215
Planeadores de la Segunda Guerra Mundial con diseños surtidos (84077)	535	102.89	48.00	4,800
Monedero de brocado con aro (17003)	239	96.47	36.00	720
Parches termoadhesivos de alfabeto para niñas (84568)	147	94.44	11.00	2,880
Collares de flores tipo lei de colores surtidos (84212)	111	92.93	24.00	1,200

Interpretación y recomendación

La media de 315.92 unidades de Frasco mediano de almacenamiento con tapa de cerámica (23166) no describe un pedido habitual. En 247 facturas, su mediana es 9 y el máximo es 74,215. La consulta de cancelaciones por código de cancelaciones.sql muestra además **77,479.64 GBP cancelados**, equivalentes al **94.83 %** de sus valores positivos. Su consulta de documentos permite revisar los registros C antes de interpretar el promedio. Aquí las cancelaciones tienen prefijo C, cantidad negativa y precio positivo. El denominador suma renglones sin C con cantidad y precio positivos.

Planeadores de la Segunda Guerra Mundial con diseños surtidos (84077) aparece en **535 facturas**, con media **102.89** y mediana **48**. Eso justifica investigar sus tamaños de lote y embalaje, sin afirmar que sean óptimos. La frecuencia responde cuántas facturas contienen el código. La mediana describe cuántas unidades contiene la factura central entre ellas.

Acción condicional. Si el catálogo confirma mercancía física y pedidos vigentes, contrastaríamos los lotes observados con cajas, existencias, costos y plazos del proveedor antes de cambiar reposición. Los datos no incluyen esa información. Manualidad de papel, pajarito (23843) queda fuera del umbral porque aparece en una sola factura positiva, pero sigue en los resultados completos para auditarlo. No se borran extremos ni se supone mayoreo a partir de una cantidad alta.

24. Referencia · Valores observados en los campos

Estos son **valores observados en los 541,909 renglones**, no el conjunto de valores que el sistema debería permitir. Un rango observado puede incluir errores, ajustes y casos extremos. No basta para definir una regla de validación.

Campo	Distintos	Valores observados o ejemplos
fila_origen	541,909	De 2 a 541,910; identifica la fila del Excel.
factura	25,900	536365, C581484 y A563186; son códigos de documentos.
producto	4,070	85123A, 23843, DOT, POST, M y B; incluye cargos y ajustes.
descripcion	4,223	Farol metálico blanco, Cargo de envío DOTCOM, Manual.
cantidad	722	De –80,995 a 80,995 unidades por renglón.
precio_gbp	1,630	De –11,062.06 a 38,970.00 GBP por unidad.
fecha	23,260	Del 2010-12-01 08:26:00 al 2011-12-09 12:50:00.
pais	38	Reino Unido, Francia, Irlanda, Islas del Canal, No especificado.

Son **4,070 códigos de artículos o cargos**, no 4,070 productos físicos. Una descripción puede variar para el mismo código. Tampoco las **38 etiquetas de pais** equivalen a 38 países soberanos. Incluyen Comunidad Europea, Islas del Canal y No especificado. Conservamos las categorías de origen, aunque sus nombres se muestran en español.

Ausentes. Solo descripcion contiene NULL, en 1,454 renglones. Los demás campos no tienen NULL, pero eso no garantiza información completa. No especificado aparece en 446 renglones de pais. CustomerID no está incluido en esta base.

Horas. Al separar la hora de la fecha, se observan registros entre 06:10:00 y 20:38:00. Son horas registradas sin zona horaria documentada, no horarios de apertura.

Qué revisaríamos. El código B contiene ajustes de deuda incobrable, incluidos dos precios de –11,062.06 GBP. El precio máximo, 38,970.00 GBP, corresponde a un renglón M (*Manual*) en C556445. No los trataríamos como precios habituales de mercancía. Los códigos DOT y POST incluyen gastos de envío.

Entre los renglones que pasan el filtro de ventas, las cantidades van de 1 a 80,995 y los precios de **0.001 a 13,541.33 GBP**. El filtro positivo tampoco certifica calidad ni elimina automáticamente los ajustes.

Las consultas de `perfil.sql` reproducen los valores distintos, rangos y ausentes.

25. Referencia · Distribución del valor por factura

El valor de una factura no es el precio de un artículo ni el valor de un solo renglón. **Agrupamos por factura y sumamos** $\text{cantidad} * \text{precio_gbp}$ antes de calcular mínimo, cuartiles, mediana y máximo. Cada documento cuenta una vez.

Usamos dos universos separados. Cada suma incluye solo los renglones que cumplen su filtro. No describe necesariamente el total íntegro de un documento si este contiene otros renglones.

- **Ventas seleccionadas** — sin prefijo C, cantidad > 0 y precio > 0.
- **Cancelaciones seleccionadas** — con prefijo C, cantidad < 0 y precio > 0.

Medida	Ventas seleccionadas	Cancelaciones seleccionadas
Documentos	19,960	3,836
Mínimo GBP	0.38	-168,469.60
Cuartil 1 GBP	152.51	-41.52
Mediana GBP	303.84	-16.85
Cuartil 3 GBP	495.62	-7.95
Máximo GBP	168,469.60	-0.39

La **mediana de ventas es 303.84 GBP**. La mitad central de los documentos queda entre **152.51 y 495.62 GBP**. Este intervalo describe el centro de la distribución. No declara inválidos los documentos fuera de él. En las cancelaciones conservamos el signo negativo. Un valor más negativo tiene mayor magnitud cancelada. No calculamos aquí una distribución de facturas netas.

Antes de decidir compras o capacidad, compararíamos el centro de la distribución y sus extremos, y revisaríamos cargos, ajustes y documentos originales. Harían falta costos, existencias y estado de los pedidos.

Reproducción. La consulta de cuantiles de `perfil.sql` calcula los cuantiles por interpolación lineal en la posición $1 + p * (n - 1)$ de los valores ordenados. Se redondea al final a dos decimales mediante SQLite. No se redondea cada renglón. El paquete incluye los resultados y una comprobación independiente en Python.

26. Archivos, fuentes y reproducción

datos/ventas.sqlite contiene líneas, movimientos y ventas. Las consultas completas, incluidas las extensiones, se encuentran en los archivos SQL. Cada extensión puede ejecutarse por separado sobre ventas.sqlite, sin modificar la base ni ejecutar antes otra extensión.

El paquete incluye datos/procedencia.json (fuente, perfil y huellas), datos/resultados.json, perfil-datos.json, popularidad.json, cancelaciones.json y tamano-pedidos.json, junto con los archivos SQL completos. Incluye también datos/patrones-temporales.json, los originales, los diccionarios de traducción y los scripts de preparación y comprobación. El README explica cómo reproducirlos. Para seguir el tutorial necesitas un navegador y ventas.sqlite.

Las tablas de resultados se generan al renderizar desde la base entregada. Las cifras de la interpretación se contrastan con las consultas y sus comprobaciones. El archivo fuente de Quarto y el estilo están incluidos; no es necesario instalarlos para seguir el tutorial.

Si ocurre...	Comprueba...
no such table: líneas	Abre la base entregada con open file
Un país no devuelve filas	Usa su texto en español entre comillas simples
No encuentras los valores ausentes	Usa IS NULL, no = NULL
El total crece al incorporar cancelaciones	Suma el valor de venta negativo una sola vez
Cambia un resultado al reabrir	Confirma la base, el filtro y la consulta guardada

Preparación y procedencia

La entrega conserva **541,909 renglones** y **25,900 códigos de factura distintos**. La SQLite ocupa **57.46 MB**. No se eliminan repeticiones ni valores extremos y no se rellenan datos ausentes. Se omite CustomerID, se renombran columnas, se normalizan fechas, se traducen las descripciones y los países y se añaden la fila de origen y las vistas.

La traducción es una adaptación didáctica, no una corrección del catálogo original. El diccionario conserva cada texto de origen, su traducción y las notas de ambigüedad. Las variantes siguen separadas y los valores NULL siguen ausentes. Los recursos permiten revisar los originales y reproducir la preparación.

Datos. Chen, D. (2015). *Online Retail*. UCI Machine Learning Repository. DOI 10.24432/C5BW33. Ficha y diccionario de variables. Licencia CC BY 4.0.

Lenguaje e historia. IBM explica el lenguaje SQL y su origen en el proyecto System R.

Motor y plataforma. SQLite y dominio público. Sqlime y funcionamiento oficial. El proyecto Sqlime publica su código bajo licencia MIT. La gratuidad de la consulta local del taller no implica que todos los motores, servicios de alojamiento o funciones externas sean gratuitos. Fuentes oficiales consultadas el 9 de octubre de 2026. Las preguntas comerciales y las interpretaciones son adaptaciones didácticas para este taller.

27. Recursos para seguir aprendiendo

Puedes seguir esta ruta a tu ritmo. Repite primero una consulta del taller, practica con otros ejercicios y después prueba una herramienta local o conecta la base con R o Python. Los títulos siguientes son enlaces a los recursos.

Sqlime

<https://sqlime.org/>

Para empezar y repetir el taller. Abre `ventas.sqlite` en el navegador, ejecuta una consulta y cambia un filtro para explicar cómo cambia el resultado. El uso básico no requiere instalar un servidor ni crear una cuenta. La interfaz está en inglés. Las conexiones con GitHub o IA son opcionales.

SQLBolt

<https://sqlbolt.com/>

Para practicar desde nivel inicial. Ofrece lecciones y ejercicios de `SELECT`, filtros, ordenación, uniones con `JOIN` y agregaciones. Está en inglés. Las lecciones consultadas eran públicas y permitían empezar sin una pantalla de registro o pago. Úsalo para practicar una idea nueva antes de aplicarla a los datos de nuestro cliente.

Referencia oficial de SQLite

<https://sqlite.org/lang.html>

Para consultar dudas al escribir SQL. Explica la sintaxis que admite SQLite. Es documentación pública en inglés y no requiere cuenta. Resulta útil para comprobar una cláusula o función. No es un curso guiado paso a paso.

DB Browser for SQLite

<https://sqlitebrowser.org/>

Para trabajar en tu equipo, desde nivel inicial. Esta aplicación de código abierto permite explorar tablas, importar CSV y ejecutar SQL mediante una interfaz gráfica. Tiene descargas públicas para Windows, macOS y Linux. El sitio está en inglés. Puedes abrir una copia de `ventas.sqlite` y guardar tus consultas para continuar sin depender de una pestaña del navegador.

RSQLite con DBI

<https://rsqlite.r-dbi.org/articles/RSQLite.html>

Para quienes ya usan R. La guía muestra cómo abrir una base SQLite, trabajar con tablas y recuperar resultados con `dbGetQuery`. Necesitas R y los paquetes DBI y RSQLite, sin instalar un servidor ni crear una cuenta para consultar la base local. La guía es pública y está en inglés.

Tutorial oficial de sqlite3 en Python

<https://docs.python.org/es/3/library/sqlite3.html#tutorial>

Para quienes ya usan Python. Enseña a conectar con SQLite y ejecutar consultas, incluidas consultas parametrizadas para pasar valores de forma segura. Necesitas Python con el módulo `sqlite3`, sin servidor ni cuenta para trabajar localmente. La documentación es pública y está en español, con algunos fragmentos en inglés.

Qué conviene recordar

Los motores comparten buena parte de SQL, pero algunas funciones y detalles cambian. Sqlime incluye extensiones de *sqlean* que no forman parte de SQLite básico. Antes de trasladar una consulta, comprueba las funciones disponibles en la herramienta de destino. Estos recursos fueron revisados el 9 de octubre de 2026.